



Write Up
Task #2 Laboratorium Ai

**"PERANCANGAN MODEL DTL, LR, DAN SVM UNTUK MEMPREDIKSI LOAN
ACCEPTANCE"**

Oleh:

Abhinaya Rajendra Fargaz - 18224087

TL;DR

Eksperimen ini berfokus pada pembangunan tiga model machine learning dari awal menggunakan NumPy murni tanpa mengandalkan pustaka eksternal maupun metode ensemble. Pendekatan utama dititikberatkan pada prapemrosesan data, rekayasa fitur finansial, dan optimasi arsitektur internal algoritma tingkat lanjut. Melalui modifikasi arsitektur decision tree yang mencakup pencarian subset optimal untuk fitur kategorik serta pemangkasan berbasis validasi silang, model berhasil mencapai skor Macro F1 sebesar 0.861 di public leaderboard Kaggle menggunakan satu pohon keputusan tunggal.

Problem Overview

Tugas ini berpusat pada upaya memprediksi status persetujuan pinjaman nasabah menggunakan dataset finansial yang memiliki ketidakseimbangan kelas target ekstrem, dengan rasio penolakan dan persetujuan sekitar 78 berbanding 22. Ketimpangan ini menjadi tantangan komputasi yang besar karena metrik evaluasi yang digunakan adalah Macro F1, yang menuntut model untuk memiliki presisi tinggi dalam mengidentifikasi kelas minoritas, bukan sekadar menebak aman di kelas mayoritas. Tantangan bertambah karena aturan melarang keras penggunaan algoritma ensemble, sehingga seluruh peningkatan akurasi harus diekstraksi secara manual melalui rekayasa data dan modifikasi matematis pada algoritma dasar.

DTL

Arsitektur Decision Tree Learning dirancang ulang secara mendalam dari baseline fungsi CART standar. Eksperimen kriteria impurity mencakup Gini Impurity, Entropy, Gain Ratio ala C4.5, dan statistik chi-square CHAID. Pada evaluasi kedalaman maksimal 8, formulasi logaritmik Entropy terbukti jauh lebih sensitif menangkap sinyal minoritas dengan Macro F1 0.8574, mengalahkan Gini di angka 0.8246.

Proses pembentukan pohon dimulai dengan memindai seluruh fitur numerik dan kategorikal untuk mencari titik belah terbaik. Alih-alih memproses data kategorikal kardinalitas rendah menggunakan ambang batas numerik linier dari hasil label encoding yang keliru mengasumsikan urutan matematis, pohon direkayasa ulang agar mampu mengeksekusi pencarian subset partisi kategorik optimal berdasarkan teorema Breiman. Teknik ini mengeksploitasi nilai informasi murni dari variabel nominal seperti status kepemilikan rumah tanpa terdistorsi urutan angka semu.

Sebagai mekanisme regulasi, pre-pruning statis disempurnakan dengan Cost-Complexity Pruning secara iteratif. Parameter penalti optimal ccp_alpha dihitung via agregasi performa Stratified 5-Fold Cross-Validation. Proses ini berhasil memangkas kompleksitas graf pohon yang overfit dari 1656 leaf menjadi hanya 59 leaf bermakna pada nilai ccp_alpha 0.0001 dengan skor rata-rata CV 0.8653. Penyelarasan meta-evaluasi dilakukan melalui threshold tuning, menggeser batas probabilitas standar 0.50 menjadi 0.74, sebuah titik ekuilibrium yang krusial untuk meminimalisasi false negatives kelas minoritas. Hasil akhir model mencetak skor 0.8649 pada holdout lokal dan 0.86102 di Kaggle.

SVM

Arsitektur SVM diimplementasikan dari awal menggunakan NumPy murni dengan pendekatan *primal soft-margin*. Mengingat kompleksitas komputasi dual form SVM dengan *kernel trick* tradisional memerlukan memori dan waktu matriks kuadratik $O(N^2)$ yang tidak mungkin dieksekusi secara efisien pada 28.800 baris data menggunakan skrip Python standar, implementasi ini dibagi menjadi dua varian utama. Pertama, *Linear SVM* yang dioptimasi menggunakan *Stochastic Gradient Descent* berbasis *Hinge Loss*. Kedua, *RBF SVM* non-linear yang mengadopsi pendekatan aproksimasi menggunakan *Random Fourier Features* untuk memproyeksikan ruang dimensi tanpa melanggar batas komputasi dasar.

Proses pelatihan model diawali dengan standardisasi skala fitur kontinu menggunakan *Z-score standardization* agar gradien konvergen secara stabil tanpa ledakan matriks. Untuk menangani ketimpangan kelas, parameter bobot penalti *soft-margin* (C) disesuaikan secara asimetris terhadap pelanggaran batas margin kelas minoritas. Melalui eksperimen *grid search*, varian *RBF SVM* dengan parameter $\gamma = 0.05$ konsisten mengungguli performa *Linear SVM* murni, masing-masing mencatatkan skor pengujian *holdout* sebesar 0.8083 berbanding 0.7844.

Meskipun sedikit di bawah performa referensi *Scikit-Learn* (0.8201) akibat penggunaan metode aproksimasi kernel, hasil ini telah sejalan dengan analisis awal. Karakteristik dataset finansial yang sangat didominasi oleh aturan diskrit berjenjang (*rule-like* seperti riwayat gagal bayar) lebih natural diselesaikan oleh percabangan logika Decision Tree daripada pemisahan batas kontinu milik SVM.

LR

Arsitektur Logistic Regression dibangun secara manual menggunakan fungsi aktivasi sigmoid dan dioptimasi melalui *Stochastic Gradient Descent* berbasis *Binary Cross-Entropy Loss*. Karena algoritma linier sangat sensitif terhadap perbedaan rentang nilai antar kolom, seluruh fitur numerik dinormalisasi menggunakan standarisasi *Z-score* sebelum memasuki proses iterasi.

Untuk mengatasi ketimpangan distribusi kelas 78:22, fungsi kerugian dimodifikasi secara matematis dengan menambahkan parameter *class weights*. Bobot penalti kelas minoritas (1) ditingkatkan secara signifikan dibanding kelas mayoritas (0), memaksa gradien turunan koefisien untuk merespons kesalahan prediksi pada nasabah berisiko secara lebih agresif. Proses optimasi ini juga dilengkapi dengan regularisasi *L2/Ridge* untuk meredam kepekaan model terhadap variasi fitur yang berlebihan.

Melalui penyetelan parameter iterasi *epoch* dan *learning rate*, model mencapai titik konvergensi yang stabil, menghasilkan skor pengujian *holdout* pada kisaran Macro F1 0.8120. Meskipun kinerjanya berada di bawah Decision Tree, hasil ini menunjukkan bahwa pendekatan linier dengan penyesuaian bobot mampu menangkap kecenderungan tren dasar dari data finansial secara konsisten.

VALIDATION

Strategi validasi yang dibangun menerapkan arsitektur isolasi ganda untuk memastikan keandalan performa model tanpa terjebak *overfitting*. Proses ini bertumpu pada kerangka *Stratified 5-Fold Cross-Validation*, yang memaksa model untuk dilatih dan dievaluasi pada lima simulasi pembagian data secara proporsional. Mekanisme *stratifikasi* ini mutlak diperlukan untuk menjaga keseimbangan rasio kelas minoritas (22%) di setiap lipatan data, sehingga model tidak mengalami bias terhadap kelas mayoritas.

Seluruh proses pencarian parameter optimal—mulai dari seleksi kriteria pembelahan, kalibrasi *threshold* prediksi, hingga pencarian nilai penalti *ccp_alpha* pada pemangkasan pohon—murni dikendalikan hanya berdasarkan rata-rata performa dari validasi silang tersebut. Untuk menguji ketahanan model secara objektif, disiapkan pula *holdout test set* lokal terisolasi yang sama sekali tidak pernah disentuh selama fase pelatihan maupun pencarian parameter atau *hyperparameter tuning*.

Pendekatan isolasi ganda ini secara matematis menciptakan miniatur sistem pengujian Kaggle di dalam lingkungan lokal. Hal ini menjawab mengapa estimasi skor lokal ($holdout = 0.8649$) mampu menempel sangat ketat dengan hasil nyata di server pengujian publik ($Public Leaderboard Kaggle = 0.86102$) dengan selisih yang sangat tipis (~ 0.004). Konsistensi ini membuktikan bahwa distribusi data antara set latih dan set uji memiliki karakteristik populasi yang seragam, serta mengonfirmasi bahwa model memiliki daya generalisasi yang tinggi tanpa adanya kebocoran data pada tahap evaluasi akhir.

GAGAL

1. Sempat dicoba pembuatan fitur interaksi baru seperti `home_ownership_x_lpi_bucket` berdasarkan analisis subgrup data. Hasil pengujian awal via satu titik hyperparameter sempat menunjukkan peningkatan semu. Namun, ketika diuji secara adil melalui *grid search* penuh di kedua sisi, selisih performa ternyata tidak signifikan secara statistik (~ 0.0024) dan berada dalam rentang standar deviasi CV. Fitur ini akhirnya dibuang karena terbukti redundan, mengingat struktur pohon keputusan secara alami mampu menangkap sinyal interaksi tersebut melalui kombinasi *split* berurutan pada fitur aslinya.
2. Sempat dilakukan upaya memaksa kedalaman pohon menjadi lebih besar (`max_depth  $\geq 15$`) sebelum proses *pruning* pada model final, terlepas dari hasil *grid search* optimal yang menyarankan kedalaman 7. Pendekatan ini memicu *overfitting* parah di mana pohon tumbuh terlalu kompleks (38 leaf dibanding 14 leaf pada titik optimal), sehingga *threshold tuning* menghasilkan angka ekstrem (0.80) yang mengeksploitasi data lokal. Hasilnya, performa saat diuji pada data eksternal justru merosot tajam, memberikan pelajaran penting bahwa kompleksitas yang tidak divalidasi silang merusak daya generalisasi model.

PENGEMBANGAN

1. **SMOTE**

Integrasi teknik penambahan sampel sintetis pada kelas minoritas berpotensi memperbaiki keseimbangan distribusi kelas.



2. **Cost-Complexity Pruning Dinamis**

Pengembangan algoritma pemangkasan dengan pengujian rentang `ccp_alpha` secara kontinu.

REFERENSI

- **Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984).** *Classification and Regression Trees*. Wadsworth & Brooks/Cole.
- **Quinlan, J. R. (1993).** *C4.5: Programs for Machine Learning*. Morgan Kaufmann.
- **Kass, G. V. (1980).** *An Exploratory Technique for Investigating Large Quantities of Categorical Data*. Applied Statistics.
- **Hastie, T., Tibshirani, R., & Friedman, J. (2009).** *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.